

Inteligență Artificială: Tema 2 - M1 aplicat

Seria CD

1. Introducere

Această lucrare explorează un set de date medicale ce vizează estimarea riscului coronarian al pacienților. Scopul este analiza exploratorie a datelor, identificarea trăsăturilor relevante, tratarea problemelor de calitate a datelor (valori lipsă, outliers, dezechilibru de clase) și antrenarea unor algoritmi de clasificare pentru a prezice apariția bolii coronariene.

2. Explorarea Datelor (EDA)

2.1 Tipuri de attribute

Am identificat trei tipuri principale de attribute:

Continue: ['cholesterol_level', 'systolic_pressure', 'daily_cigarettes', 'diastolic_pressure', 'heart_rate', 'mass_index', 'blood_sugar_level', 'age', 'sleep_heart_rate', 'ldl_cholesterol']

Discrete: ['education_level']

Ordinale: ['blood_pressure_medication', 'stroke_history', 'hypertension_history', 'smoking_status', 'diabetes_history', 'gender', 'high_blood_sugar']

Această clasificare a fost utilizată pentru a decide tipul de preprocesare și tipul de vizualizări corespunzătoare.

2.2 Valori lipsă

Am observat valori lipsă semnificative în unele attribute:

- **cholesterol_level**: 10.6% lipsă
- **smoking_status**: 9.9%
- **blood_sugar_level**: 9.4%

Acestea au fost completate folosind **imputare univariată**: mediana pentru attribute continue și moda pentru categorice.

2.3 Outlieri


Outlierii au fost identificați folosind metoda **IQR (Interquartile Range)**. Am observat variabile cu proporții ridicate de outlieri:

- **age**: 3.0%
- **blood_sugar_level**: 4.7%
- **systolic_pressure**: 2.9%

Aceste valori au fost înlocuite cu **NaN** și apoi imputate similar celor lipsă.

2.4 Vizualizări

- **Boxplot combinat (z-score scalat)** pentru variabile continue – evidențiază outlierii și variațiile mari între distribuții.



- **Histograme și countplot-uri** pentru variabilele categorice/ordinale – am remarcat un dezechilibru clar în

unele variabile (ex: `smoking_status`, `stroke_history`).

2.5 Dezechilibru de clase

Distribuția variabilei țintă `chd_risk` este puternic dezechilibrată:


- Clasa 0 (fără risc): majoritară
- Clasa 1 (cu risc): minoritară

Acest lucru impune tehnici de echilibrare a claselor înainte de antrenarea modelelor.

Corelatii puternice intre attribute:

```
cholesterol_level <--> ldl_cholesterol: corr = 0.89
diastolic_pressure <--> systolic_pressure: corr = 0.71
diastolic_pressure <--> mass_index: corr = 0.30
heart_rate <--> sleep_heart_rate: corr = 0.81
mass_index <--> systolic_pressure: corr = 0.26
age <--> cholesterol_level: corr = 0.25
age <--> systolic_pressure: corr = 0.34
age <--> ldl_cholesterol: corr = 0.25
```

Aceste corelatii se pot observa in Matricea Pearson de mai jos:




Matricea de corelație Pearson prezentată mai sus oferă o imagine de ansamblu asupra relațiilor liniare dintre variabilele numerice din setul de date. Se observă următoarele:

- **Majoritatea valorilor de corelație sunt sub 0.3**, ceea ce indică faptul că variabilele sunt în mare parte independente între ele – un aspect pozitiv pentru modele de învățare automată, deoarece reduce riscul de redundanță.
- Există totuși câteva **corelații puternice**, care merită menționate:

- `cholesterol_level` și `ldl_cholesterol` au o corelație foarte mare (≈ 0.93), ceea ce sugerează că ele conțin informații aproape identice. Pentru a evita duplicarea informației, este recomandat să păstrăm doar una dintre ele în analiza finală.
- `heart_rate` și `sleep_heart_rate` sunt de asemenea foarte corelate (≈ 0.86), fiind două măsuri apropiate ca semnificație.
- În ceea ce privește variabila țintă `chd_risk` (riscul de boli coronariene), **nu există o corelație puternică** cu nicio variabilă individuală. Totuși, cele mai relevante corelații pozitive se observă cu:
 - `age` ($r \approx 0.21$)
 - `systolic_pressure` ($r \approx 0.18$)
 - `cholesterol_level` și `ldl_cholesterol` ($r \approx 0.13 - 0.14$)
 - `diabetes_history` ($r \approx 0.09$)

Aceste rezultate indică faptul că **niciuna dintre variabile nu prezintă o relație liniară puternică** cu riscul coronarian, ceea ce sugerează că modele mai complexe (precum Random Forest sau MLP) sunt necesare pentru a surprinde interacțiunile dintre atribute.



Diagramele de mai sus arată distribuția valorilor pentru variabilele categorice și ordinale. Observații principale:

- Multe variabile sunt **puternic dezechilibrate** – de exemplu, **stroke_history**, **diabetes_history**, **high_blood_sugar** și **blood_pressure_medication** au valori de 1 (pozitiv) foarte rare.
- Variabilele precum **gender**, **smoking_status** și **hypertension_history** sunt **mai echilibrate**, ceea ce le face mai utile pentru algoritmi de clasificare.

- Distribuția pe `education_level` este variabilă, dar nu extrem dezechilibrată – potențial informativă.

Dezechilibrele identificate trebuie luate în considerare la antrenarea modelelor, deoarece pot afecta performanța și pot justifica folosirea unor metode precum **SMOTE** sau **ponderarea claselor**.

3. Preprocesarea datelor

3.1 Tratarea valorilor extreme (outlieri):

Pentru fiecare variabilă numerică continuă, valorile extreme au fost identificate pe baza metodei **IQR (Interquartile Range)** și înlocuite cu `NaN`. Această abordare permite tratarea valorilor extreme ca fiind valori lipsă, urmând să fie imputate ulterior, fără a introduce erori statistice în distribuțiile variabilelor.

3.2 Imputare și transformări:

Am aplicat o **strategie de imputare univariată**:

- Pentru variabilele numerice: mediana.
- Pentru cele categorice: cea mai frecventă valoare.

Ulterior, datele numerice au fost **standardizate** folosind `StandardScaler` pentru a aduce toate valorile la aceeași scară (distribuție $N(0,1)$).

Pentru variabilele categorice, s-a aplicat **One-Hot Encoding** cu `handle_unknown='ignore'`, pentru a permite generalizarea modelului la date necunoscute în test.

Toate aceste transformări au fost combinate într-un `ColumnTransformer`, care aplică automat pașii potriviți pentru fiecare subset de coloane.

3.3 Eliminarea atributelor redundante:

Am analizat corelațiile între variabilele numerice (doar după imputare, dar **înainte de encoding**) și am identificat perechi de variabile cu corelație absolută ≥ 0.2 . Acestea pot introduce **redundanță** și **coliniaritate**, afectând în special modele sensibile la relații liniare, cum ar fi regresia logistică.

Astfel de attribute pot fi eliminate sau tratate în etapa de selecție a caracteristicilor.

4. Modele de Învățare Automată și Evaluare – Setul „Risc Coronarian”

4.1 Tratarea dezechilibrului de clase cu SMOTE

Înainte de antrenarea modelelor, am aplicat tehnica **SMOTE (Synthetic Minority Oversampling Technique)** pentru a balansa clasele în setul de antrenament. Aceasta generează exemple sintetice pentru clasa minoritară, permițând algoritmilor de clasificare să învețe mai bine reprezentarea acestei clase.

4.2 Modele utilizate și hiperparametrii

Am evaluat patru modele clasice de clasificare binară:

- **Decision Tree:** Arbore de decizie cu adâncime maximă 5, minim 10 exemple pe frunză, criteriu Gini și ponderare automată a claselor.
- **Random Forest:** 100 arbori, fiecare construit pe subseturi aleatorii de date și caracteristici, cu max depth = 7 și class_weight='balanced'.

- **Logistic Regression:** Regularizare L2, solver **lbfgs**, max_iter=300, cu ponderare a claselor.
- **MLP (Multi-Layer Perceptron):** Arhitectură cu două straturi ascunse (50 și 25 neuroni), funcția de activare ReLU, solver Adam, early stopping activat.

4.3 Evaluarea performanțelor


Am evaluat fiecare model utilizând:

Matricea de confuzie (vizual)

Accuracy

Precision, Recall, F1-score pentru ambele clase


Rezultatele sunt sumarizate în tabelul comparativ și în graficul de mai jos. Tabelul permite o analiză detaliată a performanței fiecărui model pe clasa pozitivă (1) – care este de interes în probleme de risc.



4.4 Curbe de învățare – MLP

Am inclus și curbele de învățare pentru modelul MLP pentru a evalua comportamentul în funcție de mărimea setului de date. Curbele arată:

- dacă modelul **suferă de overfitting** (diferență mare între acuratețea de train/test),
- sau dacă este **underfit** (ambele performanțe scăzute).



4.5 Concluzii

Random Forest a avut performanțe foarte bune, fiind robust la variațiile din date.

MLP a avut o acuratețe ridicată și o generalizare bună, dar a necesitat mai mult timp de antrenare.

Logistic Regression a fost rapid, dar puțin mai slabă la recall pe clasa pozitivă.

Decision Tree este ușor de interpretat, dar cu performanță mai slabă decât ensemble-urile.

SMOTE a contribuit clar la îmbunătățirea scorurilor pe clasa minoritară, în special la recall și F1.

Explorare și analiză inițială – PIRVision

În această etapă, am încărcat seturile de date de antrenament și test pentru sistemul PIRVision, le-am concatenat pentru analiză completă și am eliminat attributele neinformative (**Day Index, Temp (C)**).

Am identificat tipurile de attribute numerice:


- **Continue** – cu multe valori unice,
- **Discrete** – cu cardinalitate medie,
- **Ordinale** – variabile binare.

Am analizat:


- **Valori lipsă**, care urmează a fi tratate prin imputare,
- **Outlieri**, eliminați pe baza IQR și înlocuiți cu NaN.

Au fost generate:

- **Statistici descriptive** pentru variabile continue și discrete,
- **Boxplot-uri** pentru distribuțiile atributelor numerice,




- **Histogramă / Countplot** pentru variabile categorice.



Am evaluat:

- **Dezechilibrul de clasă** (în favoarea clasei 0),
- **Corelații Pearson** pentru variabilele numerice – evidențiind perechi puternic corelate ($|r| > 0.9$),



Această vizualizare ne ajută să identificăm variabile **redundante sau irelevante**, care pot fi eliminate sau transformate înainte de modelare, pentru a reduce colinearitatea și a îmbunătăți performanța algoritmilor.

- **Corelații categorice** folosind testul Chi-pătrat pentru identificarea relațiilor între variabile discrete.

Această analiză oferă o bază solidă pentru preprocesare și selecția de caracteristici relevante pentru modelele ML ce vor urma.

Modelare și evaluare – PIR Vision

În această etapă, am aplicat patru algoritmi clasici de clasificare din scikit-learn pentru predicția variabilei țintă `Class` în setul de date PIR Vision:

- **Arbore de decizie (Decision Tree)**
- **Pădure aleatoare (Random Forest)**
- **Regresie logistică (Logistic Regression)**
- **Rețea neuronală de tip Multi-Layer Perceptron (MLP)**


Pentru fiecare model am folosit o funcție dedicată de evaluare care afișează:

- acuratețea pe setul de antrenament și test,
- raportul de clasificare (precizie, recall, F1-score),
- matricea de confuzie.

Parametrii utilizați:

- Toate modelele au fost **ponderate pe clase** (`class_weight='balanced'`) pentru a compensa dezechilibrul între clase.
- Random Forest a fost antrenat cu 100 de estimatori și `max_features='sqrt'`, iar MLP a avut două straturi ascunse cu `(50, 25)` neuroni și `early_stopping=True` pentru prevenirea overfittingului.

Curbe de învățare pentru MLP:




Am generat curbele de învățare pentru MLP pentru a analiza performanța acestuia în funcție de numărul de exemple de antrenament. Se poate observa dacă modelul se stabilizează sau intră în overfitting.

Rezultate:

Toate modelele au fost comparate într-un tabel și vizualizate printr-un grafic de tip barplot. Metricile analizate au fost:

- **Acuratețea de antrenare și testare**
- **Precizia, recall-ul și F1-score pentru clasa pozitivă (1)**



Acest grafic ne permite să observăm diferențele fine între modele. De exemplu, un model cu acuratețe mare dar recall scăzut poate fi inadecvat într-un context în care este esențial să identificăm cât mai multe exemple pozitive (cum ar fi detectarea prezenței într-un spațiu fizic – cazul PIR Vision).

Concluzii generale și comparative între seturi

1. Complexitatea seturilor de date

- **Risc Coronarian** are o varietate mai mare de tipuri de variabile (continue, discrete, ordinale) și un număr semnificativ de valori lipsă și outlieri.
- **PIR Vision** este mai uniform din punct de vedere al structurii (attribute numerice înregistrate în timp), dar are mult mai puține variabile explicative utile după filtrare.

2. Dezechilibru de clase

- Ambele seturi au dezechilibru de clase, dar:
 - **Risc Coronarian** are o distribuție puternic dezechilibrată în favoarea clasei 0.
 - **PIR Vision** are o distribuție dezechilibrată mai moderată.

→ În ambele cazuri, s-a aplicat **ponderare de clase** (`class_weight='balanced'`) și **SMOTE** în cazul datasetului de sănătate, pentru a asigura învățarea corectă a ambelor clase.

3. Tratatamentul outlierilor și valorilor lipsă

- În **Risc Coronarian**, am avut un volum semnificativ de valori lipsă și extreme. Acestea au fost înlocuite cu `NaN`, apoi imputate folosind **mediana** pentru variabilele continue și **modul** pentru cele categorice.
- În **PIR Vision**, outlierii au fost tratați prin limitare la percentila 1%–99%, iar lipsa valorilor a fost minimă, facilitând imputarea univariată.

→ Modelele de tip **ensemble** (Random Forest) au oferit cele mai bune rezultate în ambele cazuri, fiind robuste la variații ale datelor și outlieri.

5. Relevanța atributelor

- În **Risc Coronarian**, corelația ridicată între variabile (ex: colesterol $\leftrightarrow$ LDL) a determinat posibila redundanță, tratată prin analiză de corelație și potențială eliminare.
- În **PIR Vision**, atributele prezintă corelații scăzute între ele, deci fiecare aduce informație unică.

Concluzie finală

Această temă a demonstrat importanța unui **pipeline de analiză complet**: explorare, curățare, transformare, modelare și evaluare. Modelele performante au fost obținute nu doar datorită algoritmilor aleși, ci și datorită **preprocesării corecte**, echilibrării claselor și alegerii parametrilor potriviți.

Setul **Risc Coronarian** a necesitat o prelucrare mai complexă, dar a beneficiat de mai multă informație per eșantion, în timp ce **PIR Vision** a fost mai curat, dar cu un spațiu informațional mai restrâns.